KOSPI 대형주 200종목을 대상으로 멀티팩터 피처, 모멘텀-평균회귀 타이밍, 머신러닝(ML) 가중치 최적화를 통합한 스윙 트레이딩 시스템 설계는 여러 학술적 근거와 최신 금융 공학 기법을 활용하여 체계적으로 접근해야 합니다. 이 시스템은 종목의 본질적 가치와 시장 타이밍을 결합하고, ML 모델을 통해 예측 정확도와 포지션 최적화를 달성하여 알파 수익을 추구하는 것을 목표로 합니다.

1. 가중치 기반 매수 스코어링 시스템 설계안

통합 스윙 트레이딩 시스템의 핵심은 Layer 1(팩터), Layer 2(타이밍), Layer 3(ML)에서 산출된 정보를 종합하여 매수 스코어를 생성하는 것입니다. 이 종합 스코어는 종목의 매력도를 수치화하고, 이를 기반으로 거래 신호를 분류합니다.

1.1. 종합 매수 점수 산출 공식

종합 매수 스코어는 0부터 100까지의 값으로 정규화되며, 각 레이어의 기여도를 반영하는 가중 선형 결합 방식으로 설계될 수 있습니다. ML 모델이 최적 팩터 가중치를 자동으로 산출하는 역할을 담당하므로, ML 모델의 예측 확률이 최종 스코어에 직접적인 영향을 미 미치고, 다른 팩터들은 ML 모델의 입력으로 활용될 수 있습니다.

종합 매수 점수 $Score_{종합} = (w_{팩터} \times Normalize(Factor_Score) + w_{타이밍} \times Normalize(Timing_Score) + w_{ML} \times ML_Prediction_Probability) \times 100$ 여기서:

- $Factor_Score$는 Layer 1의 밸류, 퀄리티, 이벤트 팩터 점수를 결합한 값입니다. 각 팩터는 개별적으로 점수화되어 합산될 수 있습니다.
- $Timing_Score$는 Layer 2의 RSI, MACD, 볼린저밴드, 이격도, MA 크로스 등 기술적 지표를 결합한 값입니다. 이는 진입/청산의 적시성을 나타냅니다.
- $ML_Prediction_Probability$는 Layer 3의 ML 모델(XGBoost/LightGBM)이 예측한 향후 3~5일 수익률 방향의 상승 확률(또는 예측 수익률)입니다. ML 모델은 Layer 1과 Layer 2의 피처들을 입력으로 학습하여 이 확률을 도출합니다.
- $Normalize()$ 함수는 각 서브 스코어를 0에서 1 사이로 정규화하는 역할을 수행합니다.
- $w_{팩터}$, $w_{타이밍}$, w_{ML}은 각 레이어의 최종 스코어에 대한 가중치입니다. 이 가중치들은 고정될 수도 있지만, ML 모델의 피처 중요도 분석(예: SHAP 값)을 통해 동적으로 조정되는 것이 우수할 수 있습니다.

1.2. 각 팩터의 권장 가중치와 그 근거

ML 모델이 팩터 가중치를 최적화하므로, 초기 가중치 설정은 ML 학습의 시작점이 됩니다. 전통적인 다중 팩터 모델에서는 각 팩터가 고유한 프리미엄을 가지고 있다고 알려져 있습니다.

- **밸류(PER, PBR)**: 저평가된 주식의 장기적인 수익률 우위를 설명하는 팩터로, 역사적으로 유의미한 프리미엄을 가집니다. 한국 시장에서도 Fama-French 모델에서 밸류 팩터의 유효성이 확인됩니다.

- **퀄리티(ROE 추세, 매출 성장률 YoY)**: 재무 건전성이 우수한 기업의 주식은 안정적인 수익을 제공하는 경향이 있습니다. ROE는 기업의 수익성을 나타내며, 특히 ROE 추세는 기업의 지속적인 성장 역량을 보여줍니다.
- **모멘텀(20/60일)**: 최근의 주가 상승세가 미래에도 지속될 것이라는 현상을 반영합니다. 그러나 모멘텀 크래시(momentum crash)와 같은 시장 상황 변화에 취약할 수 있으므로, 변동성 스케일링 기법 등으로 방어 전략을 고려해야 합니다. 한국 시장에서는 단기 모멘텀 트레이딩이 개인 투자자에게 반드시 유리하지 않다는 연구도 있습니다.
- **이벤트(공시 유형별 CAR)**: 기업의 중요한 공시(예: 실적 발표, 주식 분할, 합병)는 단기적으로 주가에 큰 영향을 미칠 수 있습니다. 공시 유형별로 주가에 미치는 영향(누적초과수익률, CAR)을 분석하여 정보비율(IR) 개선 효과를 기대할 수 있습니다.
- **타이밍(RSI, MACD, 볼린저밴드, 이격도, MA 크로스)**: 시장 진입 및 청산 시점을 결정하는 데 활용되는 기술적 지표입니다. 단기 과매수/과매도, 추세 전환, 변동성 확대/축소 등의 신호를 포착하여 시장의 비효율성을 활용합니다.

이 가중치들은 ML 모델의 학습을 통해 동적으로 조정될 수 있으며, 초기 설정 시에는 각 팩터의 시장 프리미엄에 대한 학술적 근거를 바탕으로 균등하거나 중요도에 따른 상대적 가중치를 부여할 수 있습니다. 예를 들어, 멀티팩터 모델{{1}}에서는 밸류, 모멘텀, 퀄리티 팩터가 중요하게 다루어집니다.

1.3. 시그널 분류 기준: 점수 구간별 임계값

종합 매수 점수(0-100)를 기반으로 다음과 같은 시그널 분류 임계값을 설정할 수 있습니다. 이 임계값은 백테스팅 및 실전 운영을 통해 최적화될 수 있습니다.

- **Strong Buy (강력 매수)**: 85-100점. 높은 수익률 예상 및 강력한 매수 신호가 동시에 포착된 경우입니다.
- **Buy (매수)**: 65-84점. 긍정적인 수익률 예상 및 매수 고려 신호입니다.
- **Hold (보유)**: 45-64점. 현재 포지션을 유지하거나 신규 진입을 보류하는 중립 구간입니다.
- **Sell (매도)**: 25-44점. 부정적인 수익률 예상 및 매도 고려 신호입니다.
- **Strong Sell (강력 매도)**: 0-24점. 낮은 수익률 예상 및 강력한 매도 신호가 동시에 포착된 경우입니다.

2. 수도코드 (Pseudocode)

스윙 트레이딩 시스템의 일일 분석 파이프라인은 데이터 로드부터 포지션 사이징까지의 명확한 단계를 따릅니다.

2.1. 일일 분석 파이프라인 전체 흐름

```
Function Daily_Analysis_Pipeline(Date Today):
    # 1. 데이터 로드 (EOD 데이터 기준)
    Load_OHLCV_Data(Today, KOSPI_200_Stocks) # 일봉 OHLCV
    Load_Fundamental_Data(Today, KOSPI_200_Stocks) # PER, PBR, ROE, 매
출성장률 (월간/분기 업데이트 고려)
    Load_Disclosure_Data(Today, KOSPI_200_Stocks) # 공시 유형 (이벤트 팩
터)

    # 2. 피처 생성
    For each stock in KOSPI_200_Stocks:
        # Layer 1: 팩터 피처 생성 (느리게 변하는 종목 품질 점수)
        Calculate_Value_Factors(stock, PER, PBR)
        Calculate_Quality_Factors(stock, ROE_Trend, Sales_Growth_YoY)
        Extract_Event_Factors(stock, Disclosure_Type) # 공시 발생 여부
및 유형 (CAR 등)
        Combine_Layer1_Features(stock) # L1_Feature_Vector 생성

        # Layer 2: 타이밍 피처 생성 (빠르게 변하는 진입/청산 시그널)
        Calculate_Technical_Indicators(stock, OHLCV_Data):
            RSI14 = Calculate_RSI(14_days)
            MACD = Calculate_MACD(12, 26, 9)
            Bollinger_Bands = Calculate_BB(20_days, 2_stddev)
            Disparity_Ratio = Calculate_Disparity_Ratio(5_days,
20_days) # 이격도
            MA_Cross = Calculate_MA_Cross(5_MA, 20_MA, 60_MA, 120_MA)
        Combine_Layer2_Features(stock) # L2_Feature_Vector 생성

        # 통합 피처 벡터 생성
        stock.Feature_Vector = L1_Feature_Vector + L2_Feature_Vector

    # 3. ML 예측
    For each stock in KOSPI_200_Stocks:
        # 학습된 ML 모델 (XGBoost/LightGBM)에 Feature_Vector 입력
        stock.ML_Prediction_Probability =
ML_Model.predict_proba(stock.Feature_Vector) # 3-5일 수익률 상승 확률
        # 또는 stock.ML_Predicted_Return =
ML_Model.predict(stock.Feature_Vector) # 예측 수익률

    # 4. 스코어링 (종합 매수 점수 산정)
    For each stock in KOSPI_200_Stocks:
        stock.Factor_Score =
Normalize(Calculate_Combined_L1_Score(stock)) # L1 팩터들의 종합 점수
        stock.Timing_Score =
Normalize(Calculate_Combined_L2_Score(stock)) # L2 타이밍 지표들의 종합 점
수

        # 최종 매수 스코어 산출 (ML 예측 확률을 핵심으로 반영)
        # 예: ML 예측 확률에 기반하여 L1/L2 점수를 가중하거나, ML 예측 자체를 스
코어로 활용
```

```
        stock.Buy_Score =
Scale_to_100(stock.ML_Prediction_Probability) # ML 예측 확률을 0-100으로
스케일링

    # 5. 시그널 판정
    For each stock in KOSPI_200_Stocks:
        If stock.Buy_Score >= 85:
            stock.Signal = "Strong Buy"
        Else if stock.Buy_Score >= 65:
            stock.Signal = "Buy"
        Else if stock.Buy_Score >= 45:
            stock.Signal = "Hold"
        Else if stock.Buy_Score >= 25:
            stock.Signal = "Sell"
        Else:
            stock.Signal = "Strong Sell"

    # 6. 포지션 사이징 및 거래 주문 생성
    Filter_Tradable_Stocks(KOSPI_200_Stocks, Current_Portfolio,
Holding_Period_Check) # 보유 기간 초과 종목 및 신규 진입 종목 필터링
    Generate_Trade_Orders(KOSPI_200_Stocks, Current_Capital,
Risk_Tolerance):
        For each stock in Filtered_Stocks with Signal in:
            # Kelly Criterion 적용 (예측 확률 및 기대 수익률 기반)
            Optimal_Position_Size =
Calculate_Kelly_Criterion(stock.ML_Prediction_Probability,
stock.ML_Predicted_Return, Volatility_Estimate)
            If Optimal_Position_Size > 0:
                Place_Buy_Order(stock, Optimal_Position_Size) # 익일 시
가 매수
        For each stock in Current_Portfolio with Signal in or
Holding_Period_Expired(stock):
            Place_Sell_Order(stock, Current_Position_Size) # 익일 시가
매도

    Update_Portfolio_Log(Today, Trade_Orders)
End Function
```

2.2. 진입/청산 조건 (코드 수준)

- **진입 조건**:
  - `IF stock.Signal == "Buy" OR stock.Signal == "Strong Buy" THEN`
    - `position_size = Calculate_Kelly_Criterion(predicted_win_prob`

`, predicted_profit_loss_ratio, current_volatility)`
    - `IF position_size > 0 AND NOT Is_Currently_Holding(stock) THEN`
        - `Execute_Market_Buy_Order(stock, position_size, entry_price = next_day_open_price)`
        - `Set_Holding_Period_Start(stock, Today)`
        - `Set_Stop_Loss(stock, entry_price * (1 - Max_Loss_Per_Trade))`
        - `Set_Take_Profit(stock, entry_price * (1 + Target_Profit_Ratio))`

- **청산 조건**:
    - `IF stock.Signal == "Sell" OR stock.Signal == "Strong Sell" THEN`
        - `Execute_Market_Sell_Order(stock, current_position_size, exit_price = next_day_open_price)`
    - `ELSE IF Holding_Period_Expired(stock, Today, Max_Holding_Days) THEN` (3~10 영업일)
        - `Execute_Market_Sell_Order(stock, current_position_size, exit_price = next_day_open_price)`
    - `ELSE IF Current_Price <= stock.Stop_Loss_Price THEN`
        - `Execute_Market_Sell_Order(stock, current_position_size, exit_price = current_market_price)`

- `ELSE IF Current_Price >= stock.Take_Profit_Price THEN`
  - `Execute_Market_Sell_Order(stock, current_position_size, exit_price = current_market_price)`

3. 파라미터 권장 범위 표

스윙 트레이딩 시스템의 성능은 파라미터 최적화에 크게 의존합니다. 다음은 각 파라미터에 대한 권장 범위입니다. 이 값들은 KOSPI 대형주 200종목에 대한 백테스트를 통해 미세 조정되어야 합니다.

3.1. 기술적 지표 파라미터

지표 유형	파라미터	권장 범위	설명 및 근거
RSI	임계값(과매수/과매도)	(30, 70), (35, 65)	RSI 30 미만은 과매도, 70 초과는 과매수로 해석되며, 단기 반등/하락 가능성을 시사합니다. 특히 RSI 35 미만은 단기 과매도를 나타냅니다.
MACD	단기/장기 이동평균, 시그널	(12, 26, 9)	MACD 골든 크로스는 매수 신호, 데드 크로스는 매도 신호로 활용됩니다.
볼린저밴드	기간, 표준편차 승수	(20일, 2배)	볼린저밴드 하단 터치는 과매도 신호로 평균회귀 전략에 활용될 수 있으며, 변동성 확대를 나타냅니다.
이격도	(단기/장기) 이동평균	(5일, 20일) 또는 (20일, 60일)	주가와 이동평균선 간의 괴리율로, 과도한 이격은 평균회귀 경향을 나타냅니다. 최적 진입 임계값은 백테스트 필요.
MA 크로스	단기/중기/장기 이동평균	(5, 20, 60, 120일)	단기-중기 MA 골든 크로스는 상승 추세 진입, 데드 크로스는 하락 추세 진입 신호입니다. 중기 추세 확인에 MA60이 사용됩니다.

3.2. ML 하이퍼파라미터 (XGBoost/LightGBM)

앙상블 모델인 XGBoost와 LightGBM은 주가 방향 예측에 있어 우수한 성능을 보입니다. 과적합 방지를 위해 적절한 하이퍼파라미터 튜닝이 필수적입니다.

하이퍼파라미터	권장 범위 (XGBoost/LightGBM)	설명 및 근거
`learning_rate` (학습률)	0.01 - 0.1	각 부스팅 단계에서 트리의 기여도를 조절하여 모델의 복잡도를 관리합니다. 너무 높으면 과적합, 너무 낮으면 학습 시간이 길어집니다.
`n_estimators` (트리 수)	100 - 1000	앙상블에 사용될 결정 트리의 수입니다. 너무 많으면 과적합될 수 있으며, 조기 종료(early stopping)와 함께 사용됩니다.
`max_depth` (트리 최대 깊이)	3 - 10	각 결정 트리의 최대 깊이를 제한하여 모델 복잡도를 제어합니다. 깊이가 깊어질수록 과적합 위험이 커집니다.
`subsample` (샘플링 비율)	0.6 - 0.9	각 트리 학습 시 사용될 데이터 샘플의 비율입니다. 과적합 방지에 도움이 됩니다.
`colsample_bytree` (피처 샘플링 비율)	0.6 - 0.9	각 트리 학습 시 사용될 피처(특징)의 비율입니다. 과적합 방지에 도움이 됩니다.
`reg_alpha`, `reg_lambda` (L1/L2 정규화)	0.1 - 10 (로그 스케일)	L1(`reg_alpha`)과 L2(`reg_lambda`) 정규화를 통해 모델의 복잡도를 제어하고 과적합을 방지합니다.
`early_stopping_rounds` (조기 종료)	50 - 100	검증 세트 성능이 일정 라운드 동안 개선되지 않으면 학습을 조기에 중단하여 과적합을 방지하고 학습 시간을 단축합니다.

3.3. 리밸런싱/재학습 주기

각 레이어의 정보가 변동하는 속도에 따라 최적의 주기를 설정하는 것이 중요합니다.

레이어 유형	주기	설명 및 근거
팩터 (Layer 1)	월간	밸류 및 퀄리티 팩터는 기업의 펀더멘털에 기반하므로 상대적으로 느리게 변동합니다. 분기별 재무제표 발표 등을 고려하여 월간 또는 분기별 리밸런싱이 적합합니다.
타이밍 (Layer 2)	일간	기술적 지표는 일별 주가 변동에 민감하게 반응하여 진입/청산 신호를 제공하므로 매일 업데이트 및 평가되어야 합니다.
ML 재학습 (Layer 3)	주간	ML 모델은 시장 변화에 적응하기 위해 주기적으로 재학습이 필요합니다. 스윙 트레이딩의 3-10일 홀딩 기간을 고려하여 주간 재학습이 적절합니다. 금융 시계열 데이터의 교차 검증에는 Purged K-Fold와 Embargo 방법론이 중요합니다.

4. 근거 논문 목록

이 보고서의 설계 결정에 대한 주요 학술적 근거는 다음과 같습니다. 한국 시장 실증 연구를 우선적으로 포함했습니다.

- ** Machine Learning for Stock Selection**
  Rasekhschaffe, Keywan Christian, Jones, Robert C., 2019, Financial Analysts Journal.
  ML의 과적합 문제와 주가 예측 활용에 대한 기본 개념 제공.
- ** Machine Learning for Active Portfolio Management**
  Bartram, Söhnke M., Branke, Jürgen, De Rossi, Giuliano, Motahari, Mehrshad, 2021, The Journal of Financial Data Science.
  ML의 포트폴리오 관리, 신호 생성, 포트폴리오 구성 및 거래 실행에 대한 적용 강조.
- ** Evaluation of tree-based ensemble machine learning models in predicting stock price direction of movement**
  Ampomah, EK, Qin, Z, Nyame, G, 2020, Information.
  XGBoost, LightGBM 등 트리 기반 앙상블 ML 모델의 주가 방향 예측 성능 비교 및 우수성 입증.
- ** High-precision forecasting of Indian stock market indices using weighted ensemble of hyperparameter-tuned LightGBM models with diverse technical indicators**
  Samantaray, S, Mohapatra, S, 2025, N/A.
  LightGBM의 하이퍼파라미터 최적화 및 앙상블 전략을 통한 고정밀 예측 능력 강조.
- ** Active portfolio management: improving factor-based portfolio construction by applying machine learning to classify stock performance**
  Runhaar, Anton Johan, 2017, Open University of Cape Town (University of Cape Town).
  ML을 활용한 팩터 기반 투자 전략이 벤치마크를 능가하는 성과를 보일 수 있음을 시사.
- ** Stock price prediction based on xgboost and lightgbm**
  Yang, Y, Wu, Y, Wang, P, Jiali, X, 2021, E3s web of conferences.
  XGBoost와 LightGBM 결합 모델이 단일 모델 및 신경망보다 우수한 주가 예측 성능을 보임을 제시.
- ** Mean-variance Portfolio Optimization with Stock Return Prediction Using XGBoost**
  Kim, HongJoong, 2021, ECONOMIC COMPUTATION AND ECONOMIC CYBERNETICS STUDIES AND RESEARCH.
  XGBoost를 활용한 한국 주식 시장의 수익률 예측 및 포트폴리오 최적화 연구.

- ** Advances in Financial Machine Learning: by Marcos Lopez de Prado, Wiley (2018). Hardback. ISBN 978-1119482086.**
  Schwendner, P, 2020, Quantitative Finance.
  금융 시계열 데이터에 대한 교차 검증 기법, 특히 Purged K-Fold 및 Embargo 방법론의 중요성을 다룬 Marcos López de Prado의 저서.
- ** Evaluating the machine learning based momentum stock trading strategies with back-testing: An emerging market perspective**
  Kabir, AI, Vyas, S, Mitra, S, Uddin, MM, 2024, AIP Publishing.
  ML 기반 트레이딩 전략의 백테스팅 및 샤프 비율을 통한 성과 평가.
- ** Gradient Boosting with XGBoost and LightGBM**
  Korstanje, Joos, 2021, Apress eBooks.
  그래디언트 부스팅 모델, 앙상블 방법 및 조기 종료 기법에 대한 설명.
- ** Momentum, Value and Quality Investing in European Markets**
  Siirtola, JJ, 2021, N/A.
  모멘텀, 밸류, 퀄리티 팩터의 프리미엄 및 이들의 결합 전략에 대한 논의.
- ** Integrating Fundamental and Technical Analysis of Stock Market through Multi-layer Perceptron**
  Namdari, Alireza, Li, Zhaojun Steven, 2018, IEEE.
  기본적 분석과 기술적 분석의 통합이 주가 예측 정확도를 향상시킬 수 있음을 제시.
- ** Factors with Style**
  Kimura, Keiko, Schwaiger, Katharina, Sharma, Deepika, Ang, Andrew, 2021, The Journal of Investing.
  다양한 스타일 팩터(모멘텀, 밸류, 퀄리티, 사이즈)의 효과와 이들을 통합한 포트폴리오 구성 방법.
- ** Short-term trading by individual investors in the Korean stock market**
  Chung, Chune Young, Wang, Kainan, 2016, Journal of the Asia Pacific Economy.
  한국 개인 투자자들의 단기 모멘텀 트레이딩 행태와 그 결과에 대한 실증 분석.
- ** A comparison of new factor models in the Korean stock market**
  Kang, H, Kang, J, Kim, W, 2019, Asian Journal of Finance and Accounting.
  한국 주식 시장에서 Fama-French 5팩터 모델의 유효성에 대한 연구.
- ** Machine Learning Enhanced Multi-Factor Quantitative Trading: A Cross-Sectional Portfolio Optimization Approach with Bias Correction**
  Du, Y, 2025, arXiv.
  ML을 활용한 다중 팩터 퀀트 트레이딩에서 최적 가중치 결정 및 편향 보정의 중요성.
- ** Optimal Mean Reversion Trading**
  Leowski, Henri, 2017, Quantitative Finance.
  최적 평균회귀 트레이딩의 진입 및 청산 지점에 대한 수학적 분석.

- ** Market Intraday Momentum with New Measures for Trading Cost: Evidence from KOSPI Index**
  Lai, Chien Yuan, Lin, Zhen Yu, Eom, Cheoljun, Tsai, Ping-Chen, 2022, MDPI.
  KOSPI 시장의 장중 모멘텀(MIM) 전략의 수익성 및 거래 비용 고려에 대한 연구.
- ** Improving Earnings Predictions and Abnormal Returns with Machine Learning**
  Hunt, Joshua O.S., Myers, James N., Myers, Linda A., 2021, Accounting Horizons.
  ML 기법이 예측 정확도와 초과 수익률을 개선할 수 있음을 제시.
- ** Trading multiple mean reversion**
  Boguslavskaya, E., Boguslavsky, M., Muravey, D., 2022, arXiv.
  다중 평균회귀 자산의 최적 포지션 관리에 대한 연구.
- ** Exploring the effectiveness of deep neural networks with technical analysis applied to stock market prediction**
  Lee, MC, Chang, JW, Hung, JC, 2021, N/A.
  기술적 분석 지표와 딥러닝 모델의 결합이 주가 예측에 효과적임을 입증.
- ** Gross profitability and momentum**
  Bhootra, A, 2018, Managerial Finance.
  수익성(profitability)과 모멘텀 팩터를 결합한 전략이 우수한 성과를 보임을 제시.